



مدرسة علوم المعلومات  
+ΣΙCΠ I +C.ΘΘ.ΣI I ΣIYCΣΘI  
ECOLE DES SCIENCES  
DE L'INFORMATION

# ***Rapport du Projet***

Projet : Segmentation et Prétraitement d'Images Médicales et Agricoles

Préparé par :

Labyady Ibtissam

## Table des matières

Introduction générale .....	4
Chapitre 1 : Dataset.....	8
Chapitre 2 : Prétraitement et Segmentation .....	9
1-Prétraitement des images .....	9
a-Amélioration du contraste :.....	9
b-Égalisation d'histogramme :.....	10
c-Élimination du bruit :.....	11
d-Analyse de l'histogramme :.....	12
2-Segmentation.....	13
3-Évaluation .....	20
Conclusion : .....	22

## *Introduction générale:*

### Segmentation d'images

La segmentation d'images est une technique fondamentale dans le domaine du traitement d'images, qui consiste à diviser une image en plusieurs segments ou régions distinctes. Cette approche permet de faciliter l'analyse et l'interprétation des images, en donnant la possibilité de traiter chaque segment individuellement. La segmentation peut être utilisée dans de nombreux domaines, tels que la médecine, l'agriculture, la reconnaissance de formes, la vision par ordinateur, etc.

Dans le contexte médical, la segmentation d'images revêt une importance particulière. Elle permet la détection précise de structures anatomiques ou de zones pathologiques dans des images médicales, ce qui peut avoir un impact direct sur le diagnostic et le traitement des patients. Par exemple, en segmentant les images de rétine, il est possible de détecter et de suivre l'évolution de maladies telles que la rétinopathie diabétique. De même, la segmentation d'images cérébrales peut aider à identifier et à évaluer les lésions associées à la sclérose en plaques.

Dans le domaine agricole, la segmentation d'images est utilisée pour la détection des maladies des plantes et la surveillance des cultures. En segmentant les images de feuilles, de fruits ou de légumes, il est possible de détecter les zones malades et d'évaluer l'étendue des dommages. Cela permet aux agriculteurs de prendre des décisions éclairées concernant le traitement des cultures, la distribution de l'eau ou l'utilisation de pesticides.

Cependant, la segmentation d'images peut être une tâche complexe, en particulier lorsque les images présentent des variations d'éclairage, du bruit ou d'autres perturbations. C'est là qu'intervient le prétraitement des images. Le prétraitement consiste à appliquer une série de techniques pour améliorer la

qualité et la cohérence des images avant la segmentation. Cela comprend des opérations telles que la correction des variations d'éclairage, la réduction du bruit, la normalisation des contrastes, etc. Le prétraitement des images permet d'optimiser les performances des algorithmes de segmentation en réduisant les effets négatifs des perturbations sur les résultats.

### Maladie : La sclérose en plaques (SEP)

La sclérose en plaques est une maladie auto-immune qui affecte le système nerveux central, comprenant le cerveau et la moelle épinière. Elle se caractérise par une inflammation chronique qui entraîne des lésions et une démyélinisation, c'est-à-dire la destruction de la gaine de myéline qui entoure les fibres nerveuses. La myéline joue un rôle essentiel dans la transmission efficace des signaux nerveux.

Les causes exactes de la sclérose en plaques ne sont pas encore complètement comprises, mais il est largement accepté qu'elle résulte d'une combinaison de facteurs génétiques et environnementaux. La maladie touche généralement les adultes jeunes, avec une prévalence plus élevée chez les femmes que chez les hommes. Les symptômes de la sclérose en plaques peuvent varier d'une personne à l'autre et évoluer au fil du temps. Ils peuvent inclure une fatigue sévère, des troubles de la vision, des problèmes de coordination, des engourdissements, des faiblesses musculaires et des problèmes de mémoire. Ces symptômes peuvent survenir par poussées, avec des périodes de rémission entre les épisodes.

Bien qu'il n'existe pas encore de remède définitif pour la sclérose en plaques, il existe des traitements visant à atténuer les symptômes, ralentir la progression de la maladie et améliorer la qualité de vie des patients. Les approches thérapeutiques peuvent inclure des médicaments immunomodulateurs, des thérapies physiques et occupationnelles, ainsi que des changements de mode de vie. La prise en charge de la sclérose en plaques nécessite souvent une approche multidisciplinaire impliquant des neurologues, des physiothérapeutes, des ergothérapeutes, des psychologues et d'autres professionnels de la santé.

## Le rôle essentiel de la segmentation d'images dans la compréhension de la sclérose en plaques (SEP)

La segmentation d'images joue un rôle essentiel dans la compréhension et la gestion de la sclérose en plaques (SEP). En tant que maladie complexe du système nerveux central, la SEP présente des lésions qui peuvent se propager à travers la moelle épinière et le cerveau. La segmentation précise de ces lésions permet aux chercheurs et aux cliniciens d'analyser et de quantifier leur étendue, leur localisation et leur évolution dans le temps, fournissant ainsi des informations cruciales pour la prise en charge de la maladie.

L'une des utilisations principales de la segmentation d'images dans la SEP est la quantification des lésions. En segmentant les images de la moelle épinière et du cerveau, les chercheurs peuvent mesurer la charge lésionnelle totale, c'est-à-dire la quantité de tissu lésé. Cette mesure quantitative peut être utilisée pour évaluer la sévérité de la maladie, suivre sa progression au fil du temps et évaluer l'efficacité des traitements. Par exemple, une diminution de la charge lésionnelle après un traitement indique une réponse positive au traitement.

De plus, la segmentation d'images permet d'identifier et de caractériser différents types de lésions associées à la SEP. Les lésions peuvent être classées en lésions inflammatoires actives, lésions chroniques ou lésions de la substance blanche normale. En segmentant les différentes classes de lésions, les chercheurs peuvent mieux comprendre les mécanismes de la maladie et étudier les corrélations entre les caractéristiques des lésions et les symptômes cliniques. Par exemple, la segmentation peut révéler des lésions spécifiques qui sont associées à des troubles de la vision ou à des problèmes de mobilité chez les patients atteints de SEP.

La segmentation d'images permet également d'étudier les relations spatiales entre les lésions et les structures anatomiques environnantes. En délimitant précisément les lésions, il est possible de quantifier leur proximité avec des

régions critiques du cerveau ou de la moelle épinière. Cela peut aider à comprendre les conséquences fonctionnelles des lésions et à établir des liens entre certaines régions spécifiques du système nerveux central et les symptômes observés chez les patients atteints de SEP.

Enfin, la segmentation d'images peut également être utilisée pour évaluer l'efficacité des traitements dans la SEP. En comparant les images avant et après un traitement, les chercheurs peuvent mesurer les changements dans la charge lésionnelle, la taille et le nombre des lésions, ainsi que d'autres paramètres pertinents. Cette évaluation quantitative permet de déterminer si un traitement ralentit la progression de la maladie, réduit l'inflammation ou favorise la réparation des tissus.

En conclusion, la segmentation d'images joue un rôle crucial dans la compréhension, le suivi et la gestion de la sclérose en plaques. Elle permet la quantification précise des lésions, la caractérisation des différents types de lésions, l'étude des relations spatiales et l'évaluation de l'efficacité des traitements. En fournissant des données objectives et quantitatives, la segmentation d'images contribue à l'amélioration de la prise en charge de la SEP et à l'avancement des connaissances sur cette maladie complexe.

## **Chapitre 1 : Dataset**

Ce dataset contient des images IRM cérébrales de patients atteints de sclérose en plaques (SEP). L'objectif principal de ce dataset est d'identifier les lésions de

---

sclérose en plaques sur les images IRM. Les données comprennent des informations détaillées sur les patients, telles que leur sexe, leur âge, leurs antécédents médicaux, ainsi que des informations cliniques sur l'état de santé des patients. De plus, les images IRM sont accompagnées de segmentations manuelles des lésions réalisées par trois experts en radiologie et neurologie. Ces segmentations ont été validées pour les séquences IRM T1, T2 et FLAIR.

Ce dataset présente plusieurs avantages importants. Tout d'abord, il s'agit de la plus grande collection publique de données de patients atteints de SEP avec des segmentations manuelles des lésions. De plus, il contient également la plus grande quantité d'informations générales et cliniques disponibles publiquement sur les patients. Ces données peuvent être utilisées par les chercheurs en biomédecine et en informatique pour détecter et quantifier les lésions de SEP. De plus, les chercheurs en neurosciences peuvent utiliser ces données pour évaluer l'influence des anomalies cérébrales sur les handicaps des patients. Ce dataset peut être exploité dans différents domaines de recherche, tels que la segmentation automatisée des lésions de SEP, la prédiction du handicap des patients à l'aide de l'IRM et l'analyse de corrélation entre le handicap des patients et les anomalies cérébrales détectées sur l'IRM, y compris la localisation, la taille, le nombre et le type de lésions.

Les données ont été collectées auprès de patients atteints de SEP à la clinique MS-Clinic de l'hôpital d'enseignement de Bagdad, en Irak. Les images IRM ont été acquises à l'aide d'un appareil de 1,5 Tesla provenant de vingt centres différents. Les informations générales et cliniques sur les patients ont été extraites des dossiers des patients et des documents de suivi à la clinique MS-Clinic.

Le dataset est disponible sur le site Mendeley Data, où vous pouvez accéder aux images IRM, aux segmentations manuelles des lésions et aux informations sur les patients. Chaque patient a un répertoire contenant six fichiers représentant les séquences IRM T1, T2 et FLAIR, ainsi que les segmentations manuelles des lésions correspondantes.

En conclusion, ce dataset est une ressource précieuse pour la recherche sur la sclérose en plaques. Il fournit des images IRM, des segmentations manuelles des lésions et des informations détaillées sur les patients, permettant ainsi aux


---

chercheurs de mener des études approfondies sur la SEP, la quantification des lésions et la prédiction du handicap des patients.

- "XX-T1.nii": Séquence IRM T1 pour un patient avec l'identifiant XX, au format NII.
- "XX-T2.nii": Séquence IRM T2 pour un patient avec l'identifiant XX, au format NII.
- "XX-FLAIR.nii": Séquence IRM FLAIR pour un patient avec l'identifiant XX, au format NII.
- "XX-LesionSeg-T1.nii": Segmentation manuelle consensuelle des lésions pour la séquence IRM T1 d'un patient avec l'identifiant XX, au format NII.
- "XX-LesionSeg-T2.nii": Segmentation manuelle consensuelle des lésions pour la séquence IRM T2 d'un patient avec l'identifiant XX, au format NII.
- "XX-LesionSeg-FLAIR.nii": Segmentation manuelle consensuelle des lésions pour la séquence IRM FLAIR d'un patient avec l'identifiant XX, au format NII.

Voici une image IRM et son masque correspondant pour un patient spécifié, une séquence donnée et un numéro de coupe (slice) donné

Flair Image - Slice 11



Flair Mask - Slice 11





## Chapitre 2 : Prétraitement et Segmentation


### 1- Prétraitement des images

Je vais afficher l'image correspondant au patient numéro 7, à la séquence "Flair" et à la coupe numéro 11.

#### Amélioration du contraste :

Techniques d'étirement de l'histogramme :



L'utilisation de techniques d'étirement de l'histogramme permet d'augmenter le contraste de l'image en étalant la gamme des valeurs de luminosité, améliorant ainsi la visibilité des détails.





#### - Transformations logarithmiques et exponentielles :

Les transformations logarithmiques et exponentielles sont des méthodes couramment utilisées pour ajuster la luminosité des images, permettant notamment de réduire les écarts entre les valeurs de pixels et d'améliorer la perception des détails dans les zones sombres ou claires.

la transformation logarithmique :





la transformation exponentielle :



S


### Égalisation d'histogramme :

- Égalisation d'histogramme classique :  
L'égalisation d'histogramme classique redistribue les valeurs des niveaux de gris d'une image de manière à obtenir une distribution plus uniforme, améliorant ainsi le contraste global de l'image.



- Égalisation adaptative :

L'égalisation adaptative est une méthode qui ajuste l'histogramme localement dans chaque région de l'image, permettant une amélioration ciblée du contraste, en particulier dans les régions présentant des variations locales importantes.




S

### Élimination du bruit :

- Filtres spatiaux :


#### filtre moyen

Le filtre moyen calcule la moyenne des pixels voisins pour chaque pixel, réduisant ainsi les variations de bruit.



### filtre médian


Le filtre médian remplace chaque pixel par la médiane des pixels voisins, permettant de supprimer efficacement les valeurs aberrantes.



### filtre gaussien

Le filtre gaussien applique une convolution basée sur une fonction gaussienne pour atténuer le bruit tout en préservant les contours.






## 2-Segmentation :

Cette étude visait à évaluer l'efficacité de différents types de prétraitement sur la segmentation des régions d'intérêt. Pour ce faire, nous avons utilisé quatre techniques de segmentation différentes : le thresholding, la région growing, le clustering et la segmentation basée sur la couleur. Avant d'appliquer ces méthodes de segmentation, nous avons effectué plusieurs prétraitements, tels que l'amélioration du contraste, l'égalisation d'histogramme et l'élimination du bruit. L'objectif était d'analyser comment ces techniques de prétraitement affectent la précision et la qualité de la segmentation des régions d'intérêt.

Voici les résultats liés au Technique d'étirement de l'histogramme



## Evaluation des techniques de Segmentation

- Techniques d'étirement de l'histogramme

	Accuracy	Jaccard Index	Precision	Recall	Hausdorff Distance
Thresholding (Orig)	0.585632	0.016265	0.016265	1.000000	0.081646
Thresholding (Prep)	0.556778	0.015222	0.015222	1.000000	0.081646
Region Growing (Orig)	0.006851	0.006851	0.006851	1.000000	0.146098
Region Growing (Prep)	0.006851	0.006851	0.006851	1.000000	0.146098
Clustering (Orig)	0.585632	0.016265	0.016265	1.000000	0.081646
Clustering (Prep)	0.556778	0.015222	0.015222	1.000000	0.081646
HSV Color Model (Orig)	0.726242	0.022608	0.022650	0.924276	0.082508
HSV Color Model coloration (Prep)	0.819229	0.000000	0.000000	0.000000	0.082508

Le tableau présente les résultats de différentes techniques de segmentation

1. Thresholding (Orig) : Cette méthode de segmentation basée sur l'intensité, sans prétraitement, montre une accuracy de 0.586 et un indice de Jaccard de 0.016. Cependant, les autres mesures, telles que la précision et le rappel, sont très faibles, ce qui indique une mauvaise performance globale.

2. Thresholding (Prep) : En appliquant des prétraitements, les résultats de la méthode de thresholding semblent légèrement diminuer. L'accuracy est de 0.557, tandis que les autres mesures restent similaires à celles de la version sans prétraitement.

3. Region Growing : Les résultats de cette méthode, qu'elle soit utilisée avec ou sans prétraitement, montrent une très faible performance avec une accuracy et un indice de Jaccard très bas, ainsi qu'une précision et un rappel de 0.007. La distance de Hausdorff est également assez élevée, indiquant une mauvaise correspondance avec les régions d'intérêt réelles.

4. Clustering : Les résultats du clustering, qu'il soit utilisé avec ou sans prétraitement, sont similaires à ceux du thresholding. L'accuracy est de 0.586 et l'indice de Jaccard est de 0.016, avec une précision et un rappel très faibles.

5. HSV Color Model : Cette méthode de segmentation basée sur le modèle de couleur HSV montre des résultats légèrement meilleurs. L'accuracy est de 0.726, et bien que l'indice de Jaccard soit faible à 0.023, la précision et le rappel montrent une amélioration significative. Cependant, il est important de noter que la distance de Hausdorff reste élevée.

6. HSV Color Model (Prep) : Les résultats de cette méthode avec prétraitement semblent beaucoup plus prometteurs. L'accuracy augmente à 0.819, mais l'indice de Jaccard est de 0, ce qui signifie qu'il n'y a pas de chevauchement entre la segmentation réalisée et les régions d'intérêt réelles. Les mesures de précision, de rappel et de distance de Hausdorff ne sont pas calculées.

En conclusion, d'après les résultats du tableau, il semble que le modèle de couleur HSV, avec prétraitement, ait montré les résultats les plus prometteurs en termes d'accuracy et de précision. Cependant, il y a encore des améliorations à apporter, notamment en ce qui concerne l'indice de Jaccard et la distance de Hausdorff, pour obtenir une segmentation plus précise et cohérente des régions d'intérêt.

- Transformations logarithmiques

	Accuracy	Jaccard Index	Precision	Recall	Hausdorff Distance
Thresholding (Orig)	0.585632	0.016265	0.016265	1.000000	0.081646
Thresholding (Prep)	0.531204	0.014404	0.014404	1.000000	0.082508
Region Growing (Orig)	0.006851	0.006851	0.006851	1.000000	0.146098
Region Growing (Prep)	0.006851	0.006851	0.006851	1.000000	0.146098
Clustering (Orig)	0.017944	0.006928	0.006928	1.000000	0.146098
Clustering (Prep)	0.342697	0.000000	0.000000	0.000000	0.146098
HSV Color Model (Orig)	0.726242	0.022608	0.022650	0.924276	0.082508
HSV Color Model coloration (Prep)	0.389893	0.000000	0.000000	0.000000	0.146098



les résultats globaux montrent que les performances de segmentation sont généralement faibles pour toutes les techniques, à l'exception de la méthode basée sur le modèle de couleur HSV (Orig) qui présente les meilleures performances. Cependant, l'ajout de prétraitements semble avoir un impact négatif sur la plupart des méthodes, réduisant leur précision et leur indice de Jaccard.

- Transformations exponentielles

	Accuracy	Jaccard Index	Precision	Recall	Hausdorff Distance
Thresholding (Orig)	0.585632	0.016265	0.016265	1.000000	0.081646
Thresholding (Prep)	0.566620	0.015563	0.015563	1.000000	0.081646
Region Growing (Orig)	0.006851	0.006851	0.006851	1.000000	0.146098
Region Growing (Prep)	0.006851	0.006851	0.006851	1.000000	0.146098
Clustering (Orig)	0.017944	0.006928	0.006928	1.000000	0.146098
Clustering (Prep)	0.017807	0.006927	0.006927	1.000000	0.146098
HSV Color Model (Orig)	0.726242	0.022608	0.022650	0.924276	0.082508
HSV Color Model coloration (Prep)	0.672607	0.019916	0.019928	0.971047	0.082508

les résultats montrent que la méthode basée sur le modèle de couleur HSV, avec ou sans prétraitement, offre les meilleures performances en termes d'accuracy, de précision et de rappel. Cependant, l'indice de Jaccard reste relativement faible dans tous les cas, ce qui indique un chevauchement limité entre la segmentation et les régions d'intérêt réelles. La distance de Hausdorff est également relativement élevée, ce qui suggère une certaine incohérence entre les régions segmentées et les régions d'intérêt.

- Égalisation d'histogramme classique

	Accuracy	Jaccard Index	Precision	Recall	Hausdorff Distance
Thresholding (Orig)	0.585632	0.016265	0.016265	1.000000	0.081646
Thresholding (Prep)	0.251190	0.009066	0.009066	1.000000	0.123889
Region Growing (Orig)	0.006851	0.006851	0.006851	1.000000	0.146098
Region Growing (Prep)	0.006851	0.006851	0.006851	1.000000	0.146098
Clustering (Orig)	0.585632	0.016265	0.016265	1.000000	0.081646
Clustering (Prep)	0.122482	0.004639	0.004653	0.596882	0.146098
HSV Color Model (Orig)	0.726242	0.022608	0.022650	0.924276	0.082508
HSV Color Model coloration (Prep)	0.286850	0.002029	0.002044	0.211581	0.136246

les résultats montrent que la méthode basée sur le modèle de couleur HSV (Orig) offre les meilleures performances en termes d'accuracy, de précision et de rappel.

- Égalisation adaptative

	Accuracy	Jaccard Index	Precision	Recall	Hausdorff Distance
Thresholding (Orig)	0.585632	0.016265	0.016265	1.000000	0.081646
Thresholding (Prep)	0.544998	0.014834	0.014834	1.000000	0.082508
Region Growing (Orig)	0.006851	0.006851	0.006851	1.000000	0.146098
Region Growing (Prep)	0.006851	0.006851	0.006851	1.000000	0.146098
Clustering (Orig)	0.017944	0.006928	0.006928	1.000000	0.146098
Clustering (Prep)	0.544998	0.014834	0.014834	1.000000	0.082508
HSV Color Model (Orig)	0.726242	0.022608	0.022650	0.924276	0.082508
HSV Color Model coloration (Prep)	0.537231	0.014365	0.014368	0.984410	0.113382

les résultats montrent que la méthode basée sur le modèle de couleur HSV (Orig) offre les meilleures performances en termes d'accuracy, de précision et de rappel.

- Filtres spatiaux:  
filtre moyen

	Accuracy	Jaccard Index	Precision	Recall	Hausdorff Distance
Thresholding (Orig)	0.585632	0.016265	0.016265	1.000000	0.081646
Thresholding (Prep)	0.625824	0.015892	0.015926	0.881960	0.082384
Region Growing (Orig)	0.006851	0.006851	0.006851	1.000000	0.146098
Region Growing (Prep)	0.009720	0.006871	0.006871	1.000000	0.146098
Clustering (Orig)	0.017944	0.006928	0.006928	1.000000	0.146098
Clustering (Prep)	0.625824	0.015892	0.015926	0.881960	0.082384
HSV Color Model (Orig)	0.726242	0.022608	0.022650	0.924276	0.082508
HSV Color Model coloration (Prep)	0.769669	0.026694	0.026755	0.922049	0.082508

les résultats montrent que la méthode basée sur le modèle de couleur HSV (Orig) offre les meilleures performances en termes d'accuracy, de précision et de rappel. La méthode de thresholding avec prétraitement présente également des améliorations par rapport à la version originale, mais les autres méthodes de segmentation (Region Growing et Clustering) restent moins performantes.

,filtremédian

	Accuracy	Jaccard Index	Precision	Recall	Hausdorff Distance
Thresholding (Orig)	0.585632	0.016265	0.016265	1.000000	0.081646
Thresholding (Prep)	0.055008	0.007118	0.007119	0.988864	0.146098
Region Growing (Orig)	0.006851	0.006851	0.006851	1.000000	0.146098
Region Growing (Prep)	0.009171	0.006867	0.006867	1.000000	0.146098
Clustering (Orig)	0.017944	0.006928	0.006928	1.000000	0.146098
Clustering (Prep)	0.622330	0.016178	0.016205	0.906459	0.146098
HSV Color Model (Orig)	0.726242	0.022608	0.022650	0.924276	0.082508
HSV Color Model coloration (Prep)	0.827408	0.020777	0.021160	0.534521	0.080647

les résultats montrent que la méthode basée sur le modèle de couleur HSV (Orig) offre les meilleures performances en termes d'accuracy, de précision et de rappel.

## Conclusion

En général, les résultats présentés dans les précédentes analyses indiquent que les performances de segmentation ne sont pas encore satisfaisantes. Les méthodes de segmentation évaluées, telles que le thresholding, le region growing et le clustering, ont montré des performances limitées en termes d'accuracy, d'indice de Jaccard, de précision et de rappel.

La méthode basée sur le modèle de couleur HSV a démontré de meilleures performances par rapport aux autres méthodes, avec des valeurs d'accuracy, d'indice de Jaccard, de précision et de rappel relativement plus élevées. Cependant, même cette méthode n'a pas atteint des performances optimales, avec un indice de Jaccard et une précision encore faibles.

La distance de Hausdorff, qui mesure la différence entre les régions segmentées et les régions d'intérêt réelles, est également relativement élevée pour toutes les méthodes, indiquant une certaine incohérence ou divergence entre les régions segmentées et les régions d'intérêt.

Ces résultats suggèrent qu'il y a encore place à l'amélioration de la précision et de la cohérence des méthodes de segmentation évaluées. Des ajustements et des optimisations supplémentaires peuvent être nécessaires pour obtenir des résultats plus précis et cohérents.

### 3- Évaluation de la dataset :

Les résultats de l'évaluation des différentes méthodes de segmentation ont montré que la méthode basée sur l'image originale a obtenu des performances relativement meilleures par rapport aux autres méthodes évaluées. Bien que les performances ne soient pas encore optimales, l'utilisation de l'image originale présente certains avantages.

	Accuracy	Jaccard Index	Precision	Recall
\				
Thresholding (Orig)	0.759724	0.011752	0.012008	0.528283
Region Growing (Orig)	0.005081	0.003863	0.003863	0.748485
Clustering (Orig)	0.590739	0.008691	0.008872	0.441703
HSV Color Model (Orig)	0.870046	0.010718	0.011469	0.281301

D'après les résultats fournis, voici une analyse des performances des différentes méthodes de segmentation :

- La méthode de segmentation par thresholding (Orig) présente une accuracy de 0,759724, un indice de Jaccard de 0,011752, une précision de 0,012008 et un rappel de 0,528283. Ces résultats indiquent une mesure relativement élevée de la proportion de pixels correctement classés, mais une faible intersection entre la segmentation et les régions d'intérêt réelles.

- Les méthodes de region growing (Orig) et de clustering (Orig) montrent des performances très faibles. La méthode de region growing présente une accuracy de 0,005081, un indice de Jaccard de 0,003863, une précision de 0,003863 et un rappel de 0,748485. La méthode de clustering obtient une accuracy de 0,590739, un indice de Jaccard de 0,008691, une précision de 0,008872 et un rappel de 0,441703. Ces résultats suggèrent une segmentation inefficace et un chevauchement limité avec les régions d'intérêt réelles.

- La méthode basée sur le modèle de couleur HSV (Orig) présente de meilleures performances par rapport aux autres méthodes évaluées. Elle obtient une accuracy de 0,870046, un indice de Jaccard de 0,010718, une précision de 0,011469 et un rappel de 0,281301. Bien que les performances soient relativement meilleures, l'indice de Jaccard et la précision restent relativement faibles, indiquant une certaine discordance entre la segmentation et les régions d'intérêt réelles.

En résumé, les résultats montrent que la méthode basée sur le modèle de couleur HSV (Orig) offre les meilleures performances en termes d'accuracy, mais les indices de Jaccard, de précision et de rappel restent relativement faibles pour toutes les méthodes évaluées. Cela suggère qu'il y a encore place à l'amélioration pour obtenir une segmentation plus précise et cohérente.

## Conclusion :

La segmentation d'images joue un rôle essentiel dans la compréhension de la sclérose en plaques (SEP) en permettant d'identifier et de délimiter les lésions présentes dans le cerveau des patients. Dans le cadre de notre étude, nous avons évalué différentes méthodes de segmentation pour leur performance dans la détection des lésions de la SEP.

Les résultats obtenus ont révélé que les performances de segmentation étaient encore perfectibles, quelles que soient les méthodes évaluées. Les méthodes de segmentation par thresholding, region growing et clustering ont présenté des performances limitées, avec des indices de Jaccard, des précisions et des rappels relativement faibles.

Cependant, la méthode basée sur le modèle de couleur HSV s'est avérée être la plus performante parmi les méthodes évaluées, avec une accuracy relativement élevée. Bien que cette méthode ait obtenu de meilleurs résultats, les indices de Jaccard et les précisions restaient encore faibles, indiquant une certaine discordance entre la segmentation et les régions d'intérêt réelles.

Il est important de souligner que ces résultats ne sont pas encore optimaux et qu'ils mettent en évidence la nécessité d'améliorer les performances de segmentation pour une détection plus précise des lésions de la SEP. Des ajustements de paramètres, des techniques de prétraitement supplémentaires ou l'exploration de nouvelles approches peuvent être envisagés pour atteindre cet objectif.

En conclusion, bien que les résultats actuels aient mis en évidence des performances encore perfectibles, la segmentation d'images demeure un outil crucial pour la compréhension de la sclérose en plaques. Les résultats obtenus serviront de base pour orienter les futures recherches visant à améliorer la précision et la cohérence de la segmentation dans le contexte de la SEP, contribuant ainsi à une meilleure compréhension et prise en charge de cette maladie neurologique complexe.

